

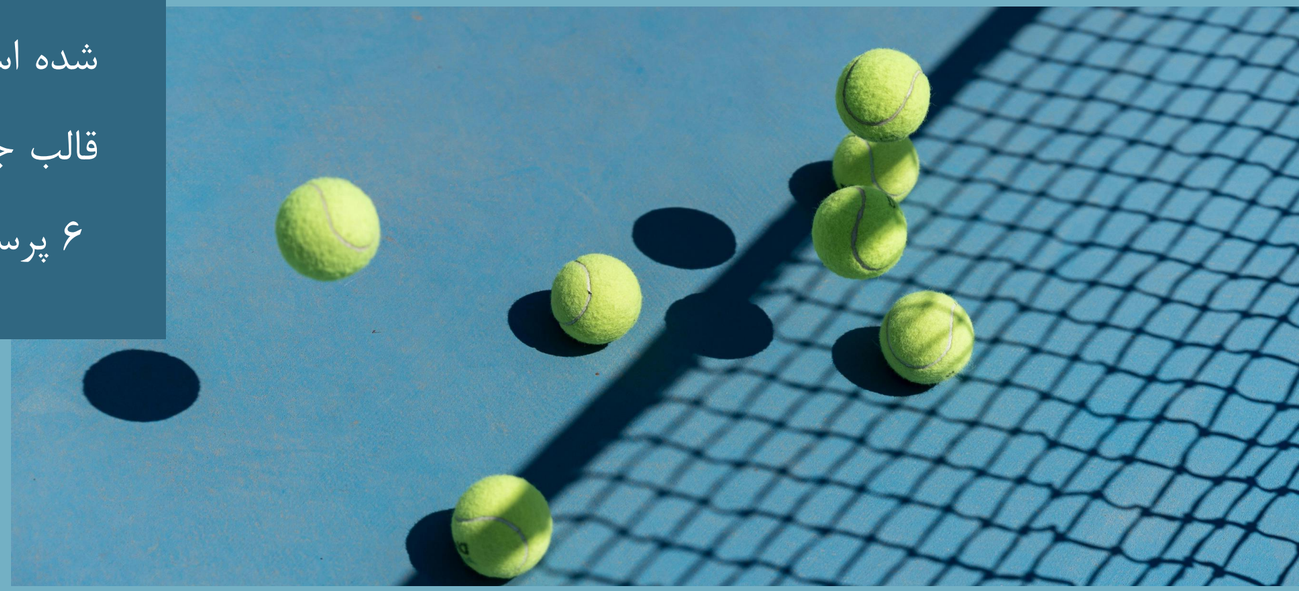
تحلیل و بررسی پروژه تنیس

اسماء میرزایی مهدیه نمازی محدثه رفیقی

مقدمه و هدف پروژه



این پروژه با هدف تحلیل آماری و کاوش داده در دنیای تنیس حرفه‌ای انجام شده است. داده‌ها از وب‌سایت Sofascore جمع‌آوری، پاکسازی و در قالب جداول ساخت‌یافته سازمان‌دهی شده‌اند تا به ۱۷پرسش اصلی پروژه و ۶ پرسش تحلیلی طراحی‌شده پاسخ داده شود.



معرفی داده و ساختار فایل‌ها

۶۰

فایل زیپ روزانه
از ۱ فوریه تا ۳۱ مارس ۲۰۲۴

~۳۵K

رکورد مسابقه

قبل از حذف تکراری ها

۵

منبع داده تخت

statistics, power, odds, pbp, votes

۱۰

منبع داده مسابقه

event, home_team, away_team, home_team_score,away_team_score tournament, season, round, venue, time

پیش‌پردازش و پاک‌سازی داده

۱. بارگذاری از ZIP تودرتو

خواندن فایل‌های parquet از داخل ZIP روزانه بدون استخراج روی دیسک

۲. حذف تکراری‌ها

یک مسابقه ممکن است در چند روز ظاهر شود؛ drop_duplicates روی match_id

۳. ساخت Master Table

ادغام جداول روی match_id با پیشوند ستون‌ها برای جلوگیری از تداخل نام

۴. اعتبارسنجی قوانین تنیس

بررسی امتیازات، ست‌ها و قوانین امتیازدهی استاندارد

۵. پاک‌سازی جداول آماری

statistics, point-by-point, power, odds — حذف مقادیر نامعتبر

۶. فیلتر مسابقات ناقص

حذف بازنشستگی‌ها، نتایج ناقص و مسابقات بدون برنده مشخص

ساخت جدول یکپارچه
Master Table

شروع از جدول event (یک ردیف به ازای هر مسابقه) و
ادغام چپ (left join) با سایر جداول روی match_id

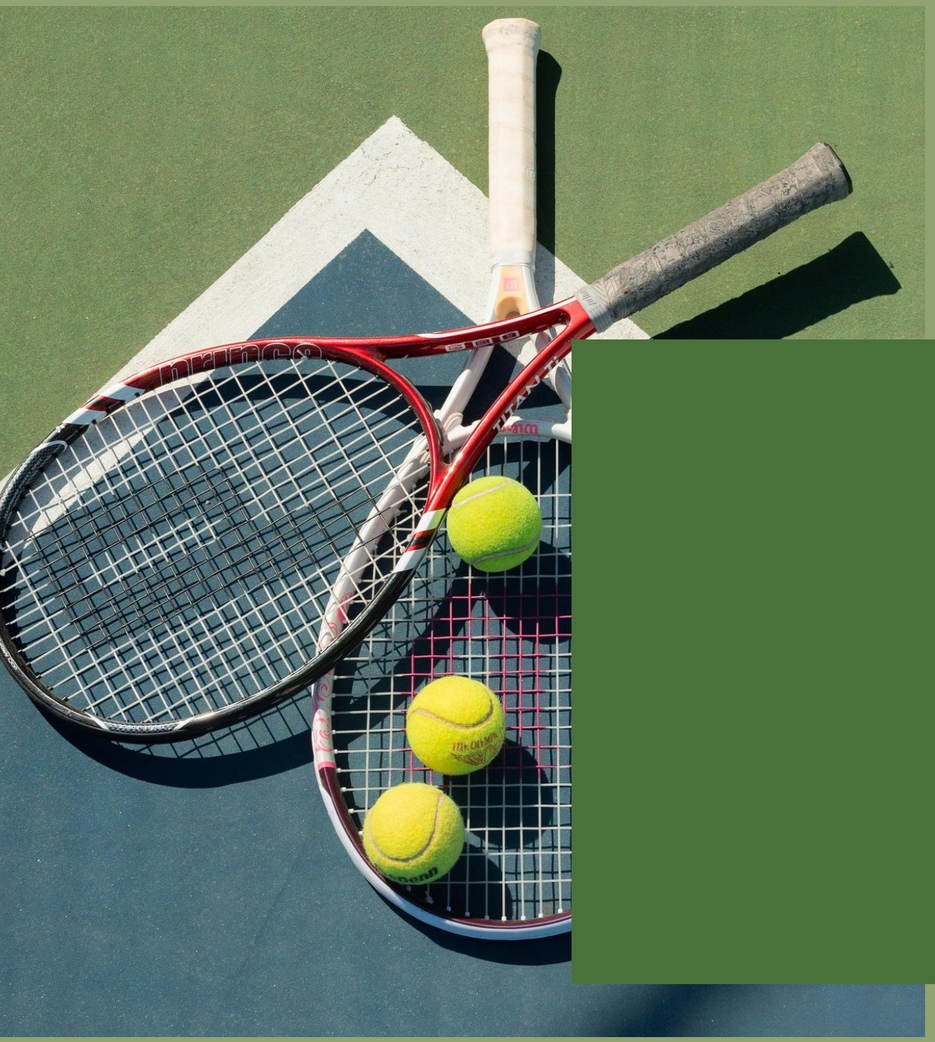
event	Home_team	away_ team	home_score	away_score
35,053 10 columns	25,610 18 columns	24,203 18 columns	35,164 14 columns	35,053 14 columns

tournament	season	round	venue	time
35,671 16 columns	35,671 4 columns	19,283 5 columns	35,423 5 columns	35,671 7 columns

حذف تکراری‌ها و پاک‌سازی اولیه جداول اصلی

مقایسه تعداد سطرهای جداول قبل و بعد از پاک‌سازی ها

index	Table	Rows Before	Rows After	Rows Removed	Removed (%)
0	statistics	1358234	657655	700579	51.58
1	odds	60946	60072	874	1.43
2	power	469677	227890	241787	51.48
3	votes	35658	35373	285	0.80
4	master	316802	16739	300063	94.72
5	Point by point	2549369	1252416	1296953	50.87



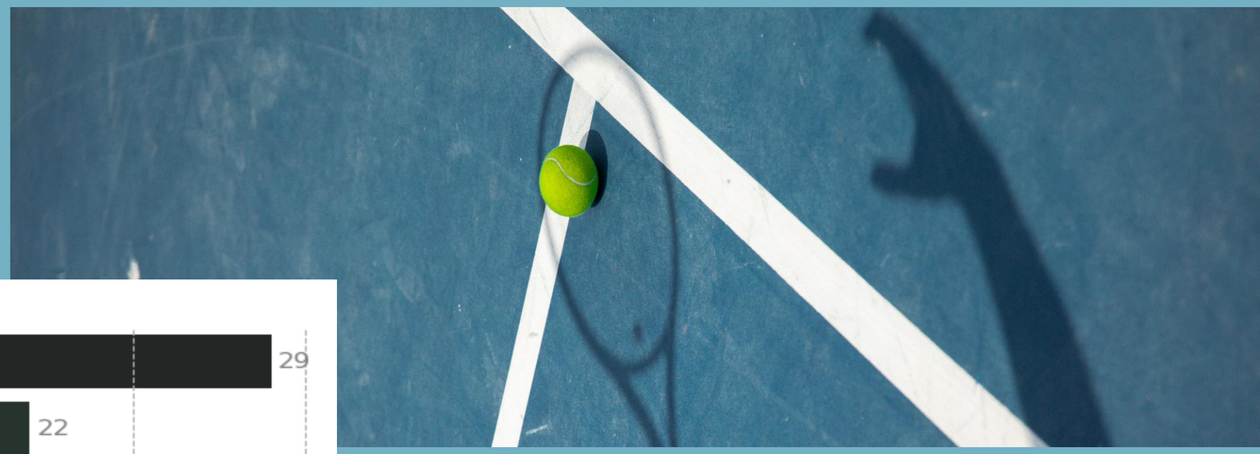
سوال ۱: چند بازیکن تنیس در مجموعه داده‌ها وجود دارد؟

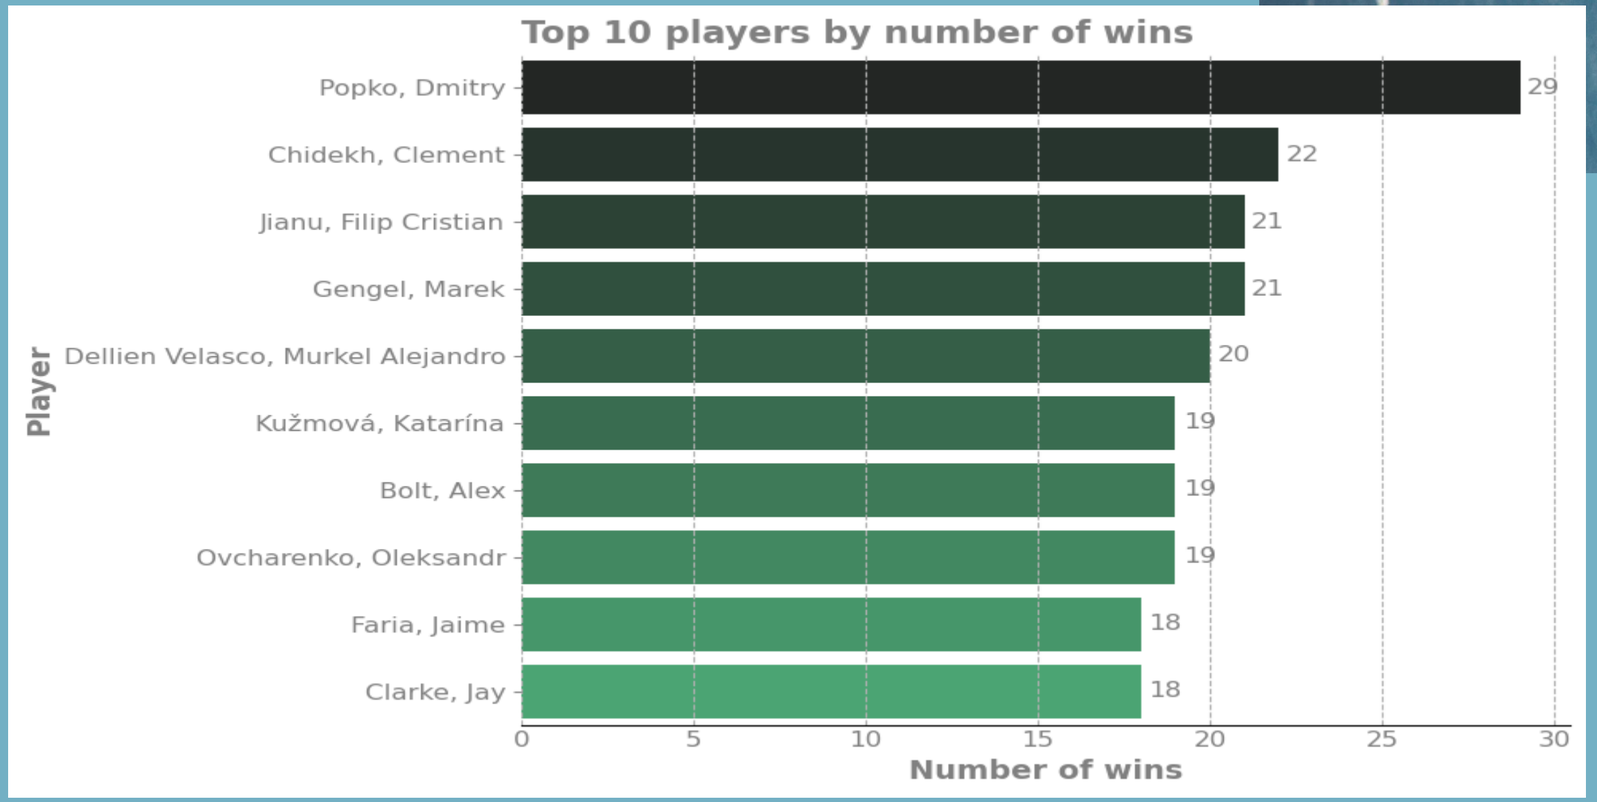
۲۶۴۳ تعداد کل بازیکنان ثبت شده در دیتا

سوال ۲: میانگین قد بازیکنان چقدر است؟

۱۸۲ سانتی‌متر میانگین قد بازیکنان

سوال ۳: کدام بازیکن بیشترین تعداد برد را دارد؟

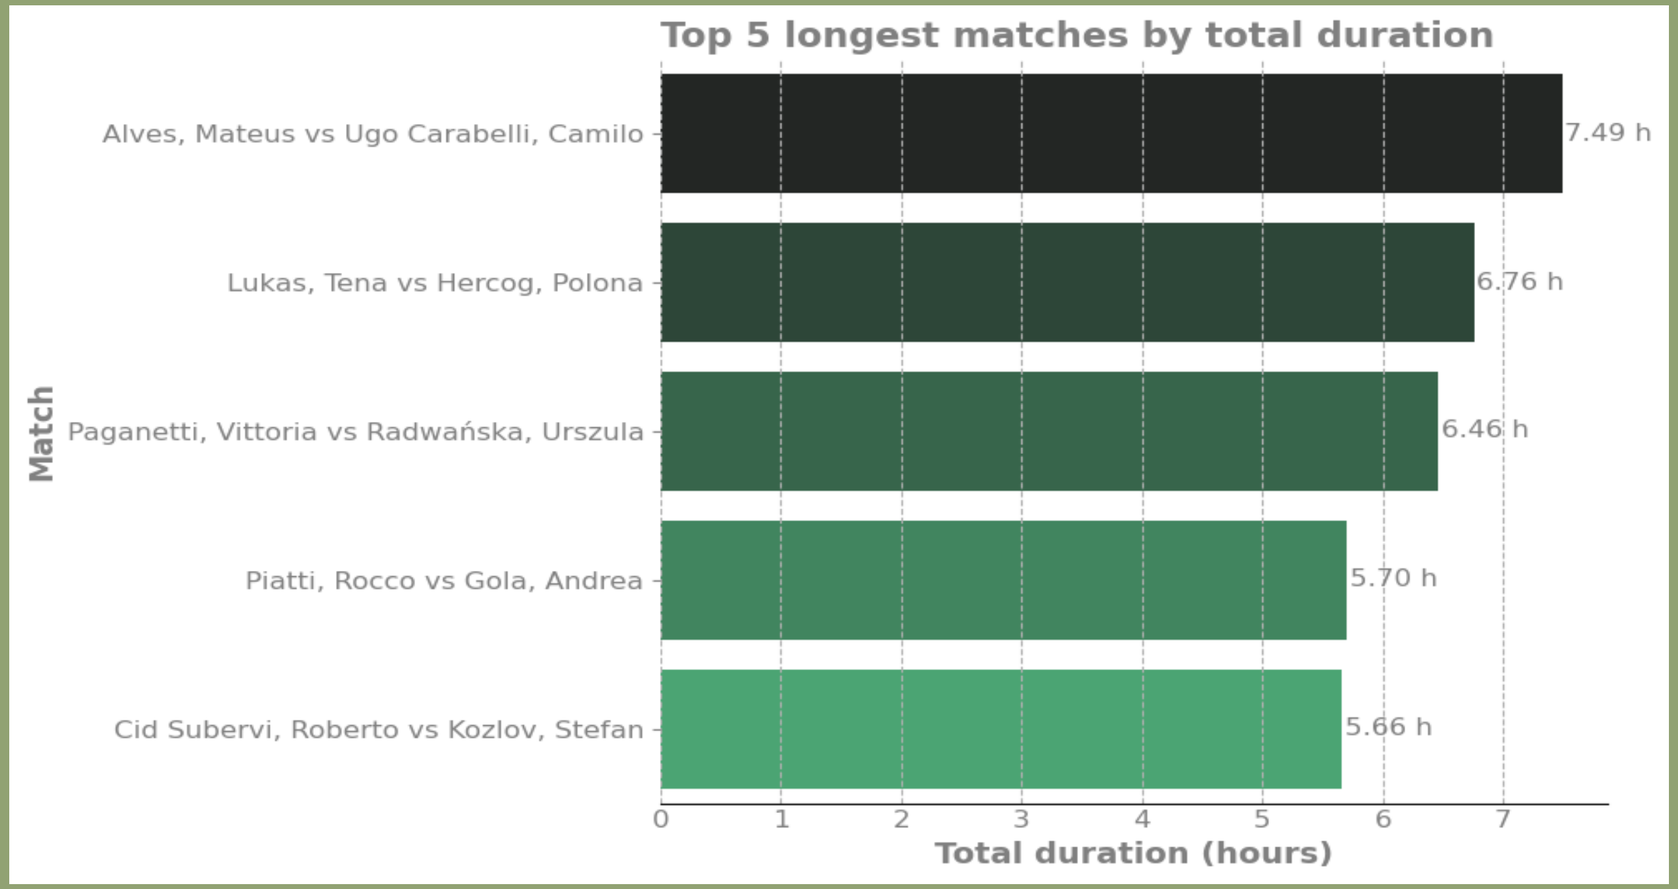




Popko, Dmitry با ۲۹برد، بیشترین تعداد پیروزی فردی در دیتاست را به‌ثبت رسانده است.



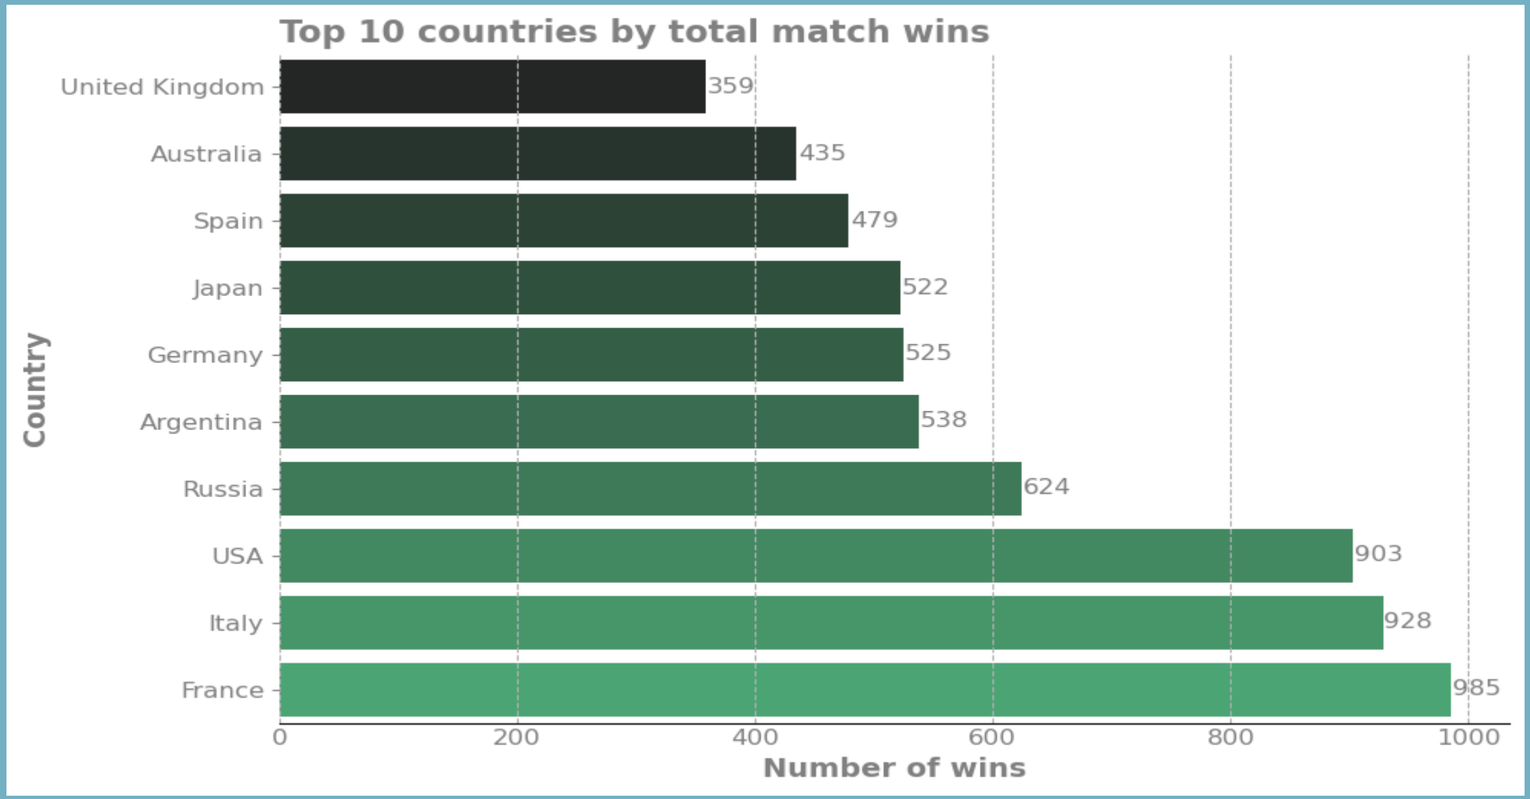
سوال ۴: طولانی‌ترین مسابقه ثبت شده از نظر مدت زمان چقدر است؟



سوال۵ : معمولاً در یک مسابقه تنیس چند ست بازی می‌شود؟

رایج‌ترین: ۲ ست (روی ۹۴۲۶ مسابقه)

میانگین: ۲,۲۸ ست

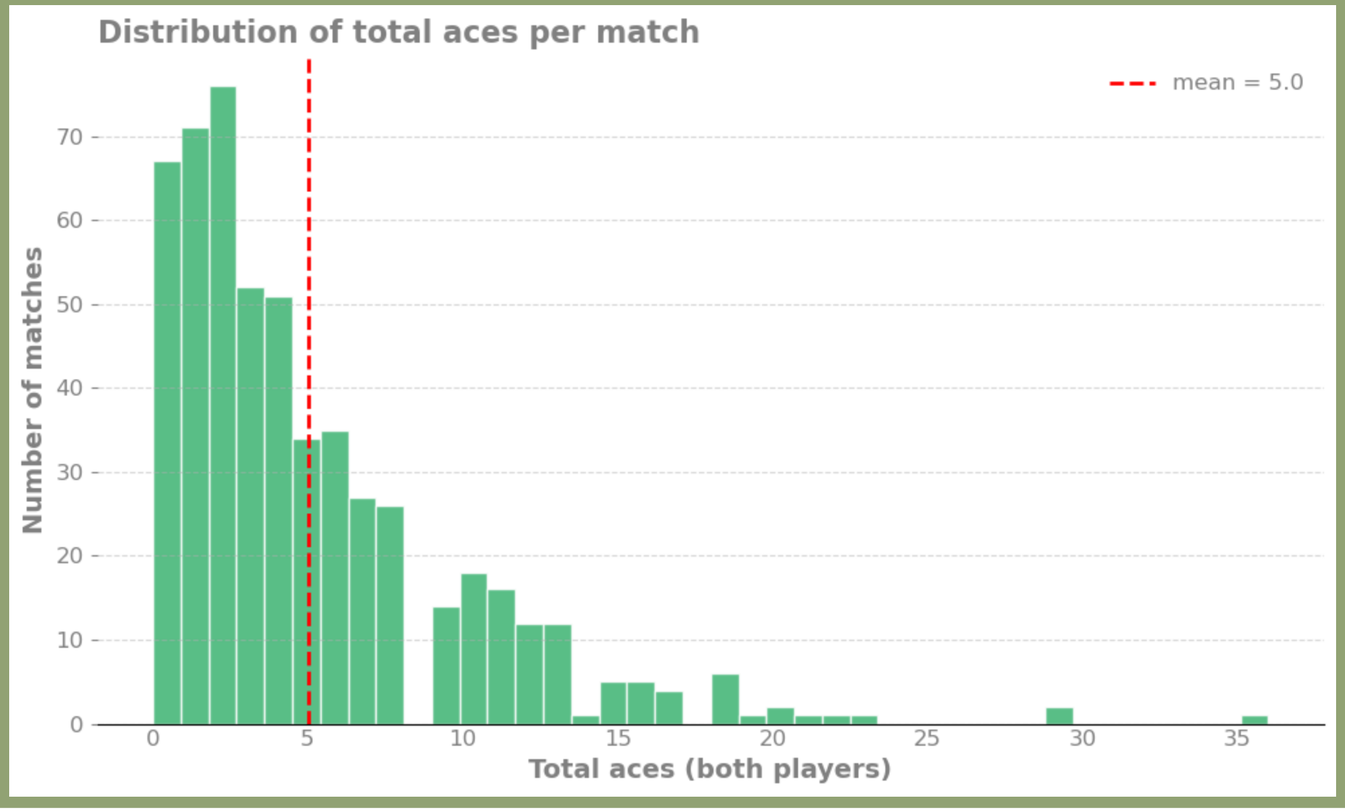


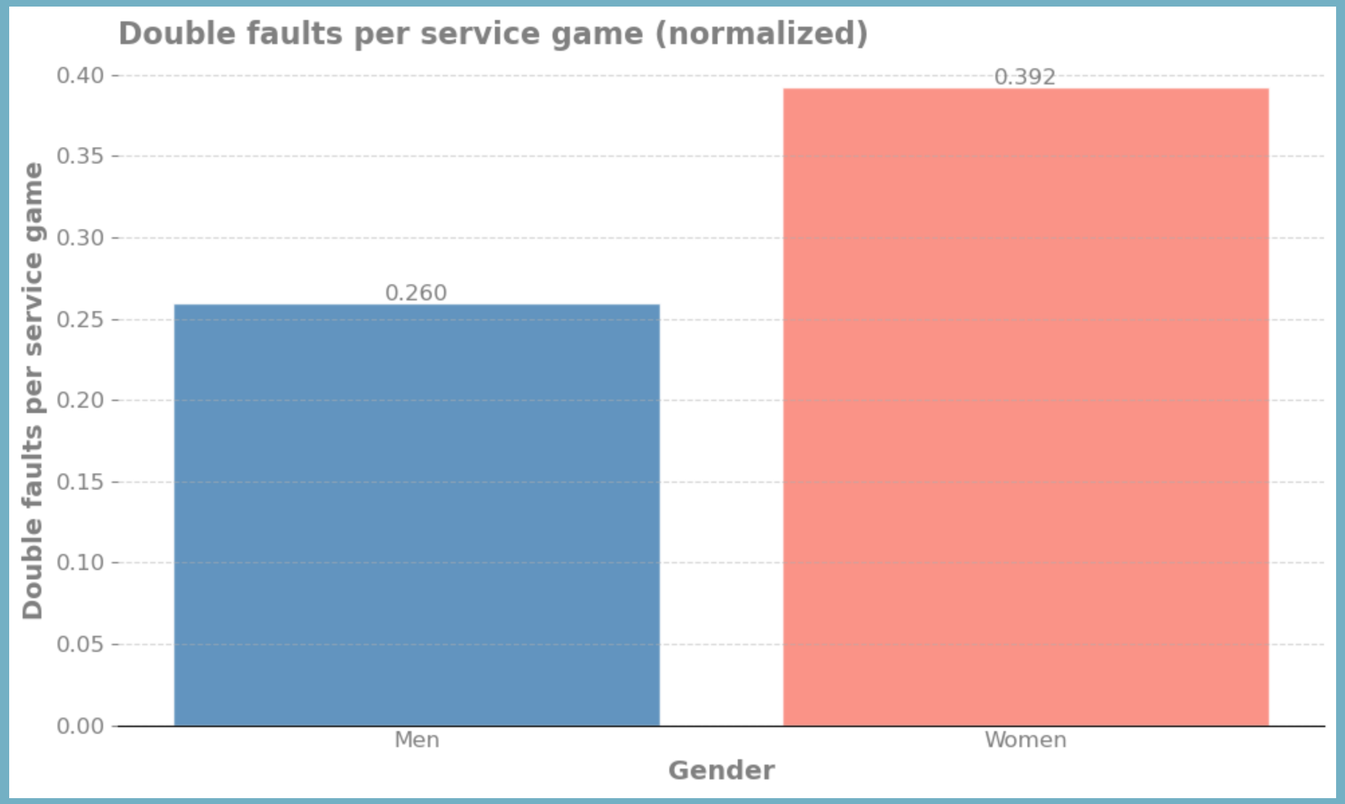
سوال۶ : کدام کشور موفق‌ترین بازیکنان تنیس را تربیت کرده است؟

سوال ۷: میانگین تعداد اِیس (Ace) در هر مسابقه چقدر است؟

۵.۰

آس در هر مسابقه



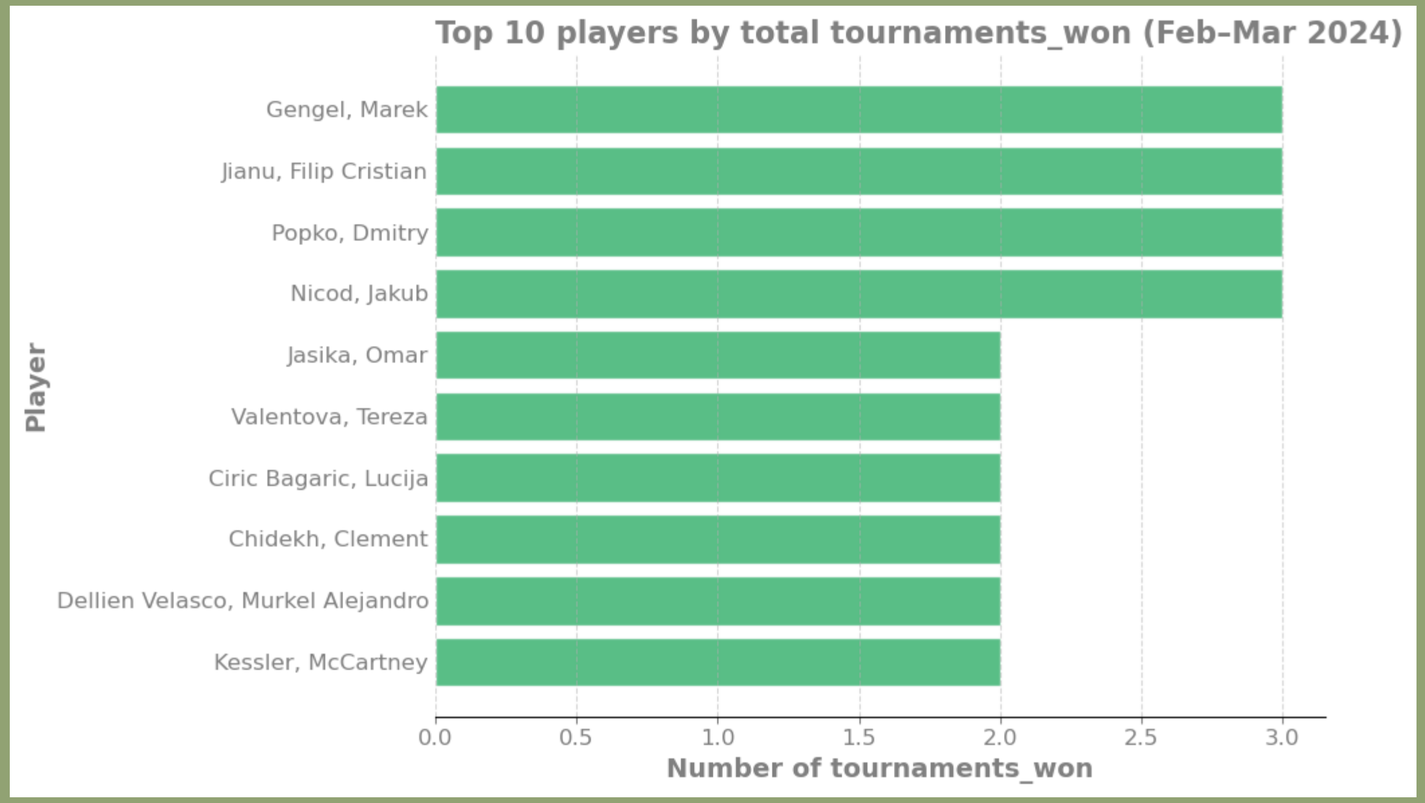


سوال ۸: ایا تعداد خطای دوگانه (Double Fault) بر اساس جنسیت تفاوت دارد؟

Mann-Whitney U test
U statistic: 57988.0
p-value: 1.0944585305748929e-07
Result: There is a statistically significant difference in double faults by gender.

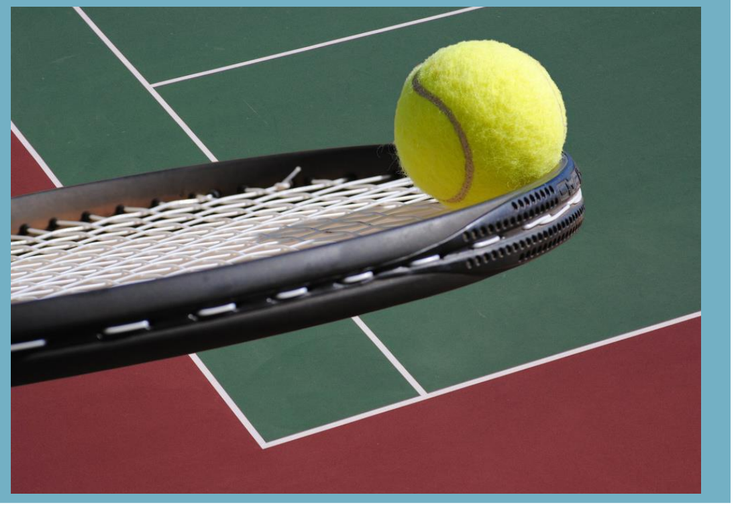
gender	total_double_faults	total_service_games	player_matches	df_per_service_game
Women	1264.0	3289.0	342	0.3843
Men	1103.0	4230.0	423	0.2608

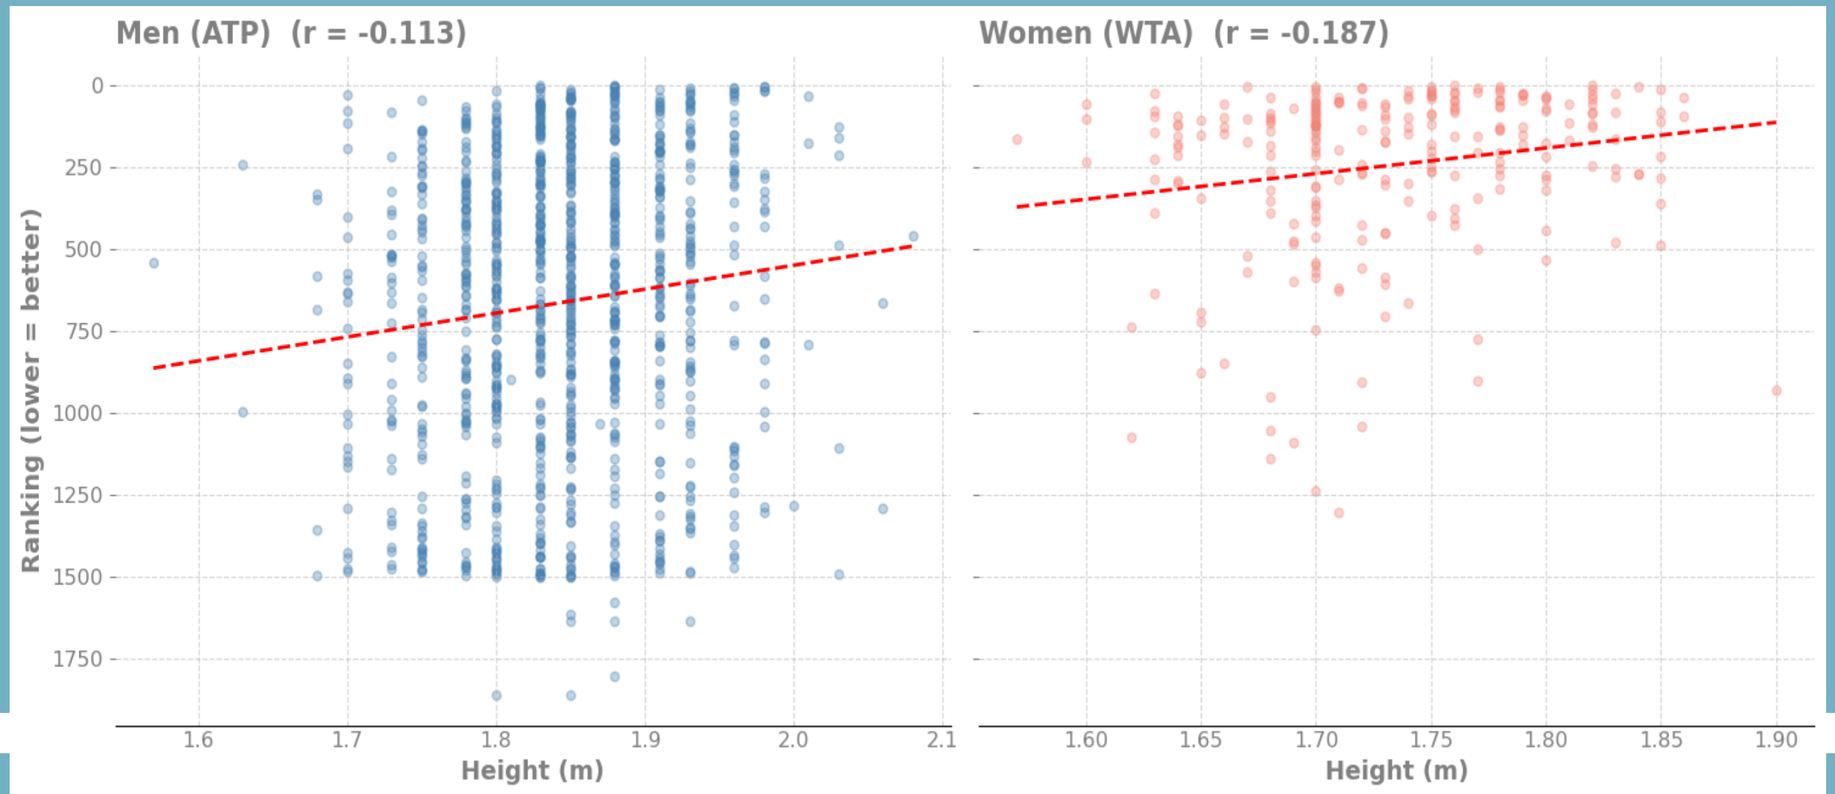
سوال ۹ : کدام بازیکن در یک ماه بیشترین قهرمانی را کسب کرده است؟

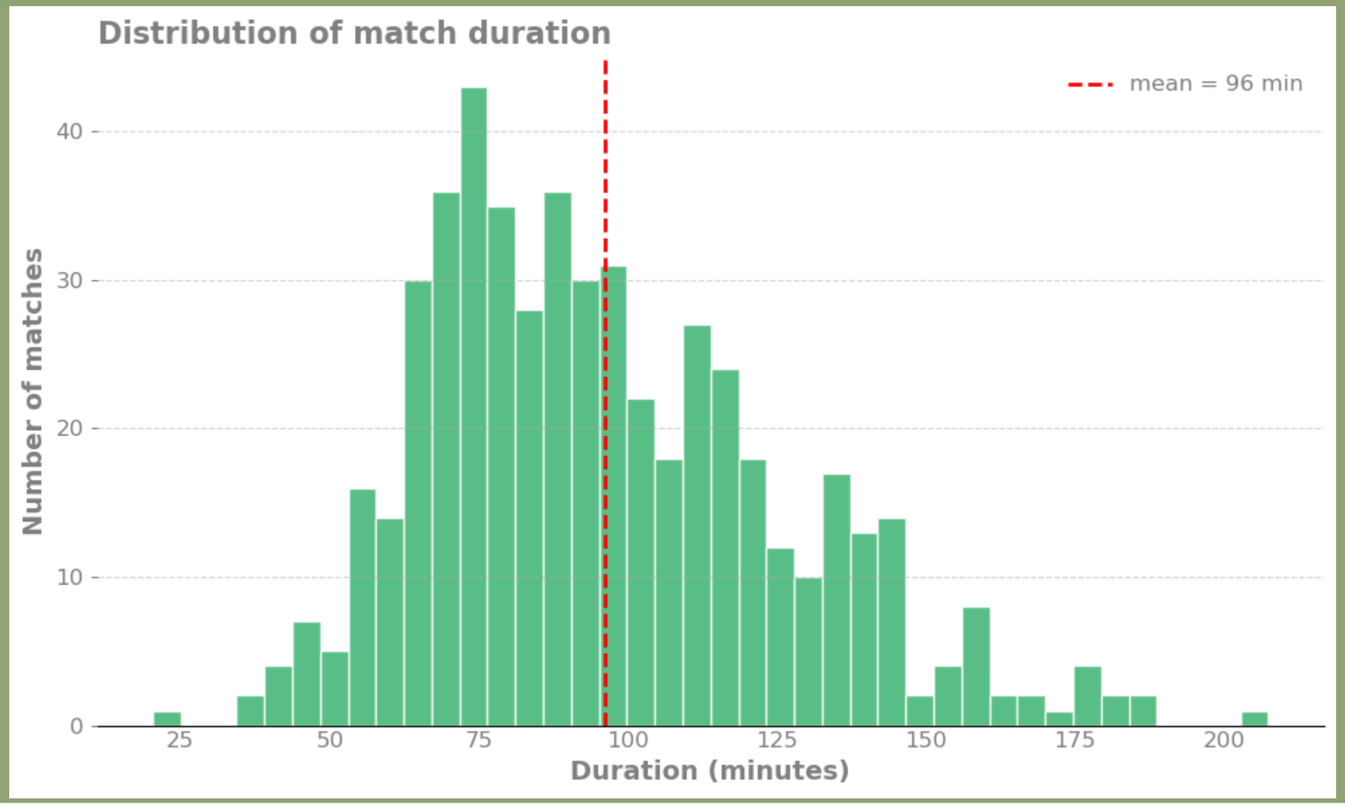


group	correlation	p_value	mean_height	players	significant
Men (ATP)	-0.123	0.0001	1.843	1081	Yes
Women (WTA)	-0.225	0.0003	1.732	252	Yes

سوال ۱۰: آیا بین قد بازیکن و رنکینگ او رابطه‌ای وجود دارد؟



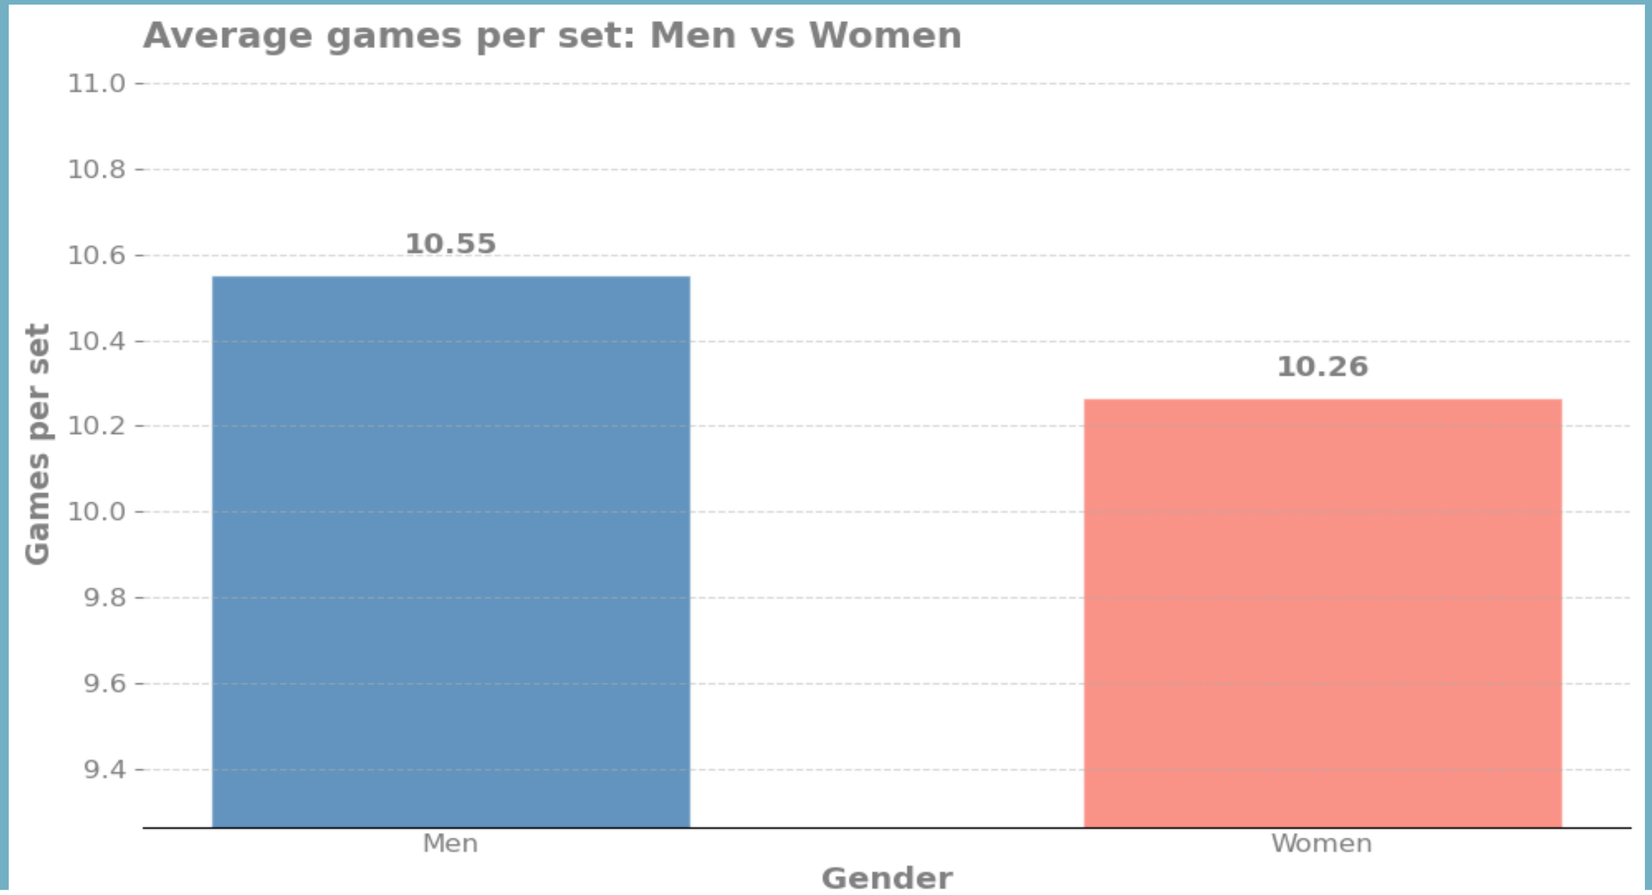


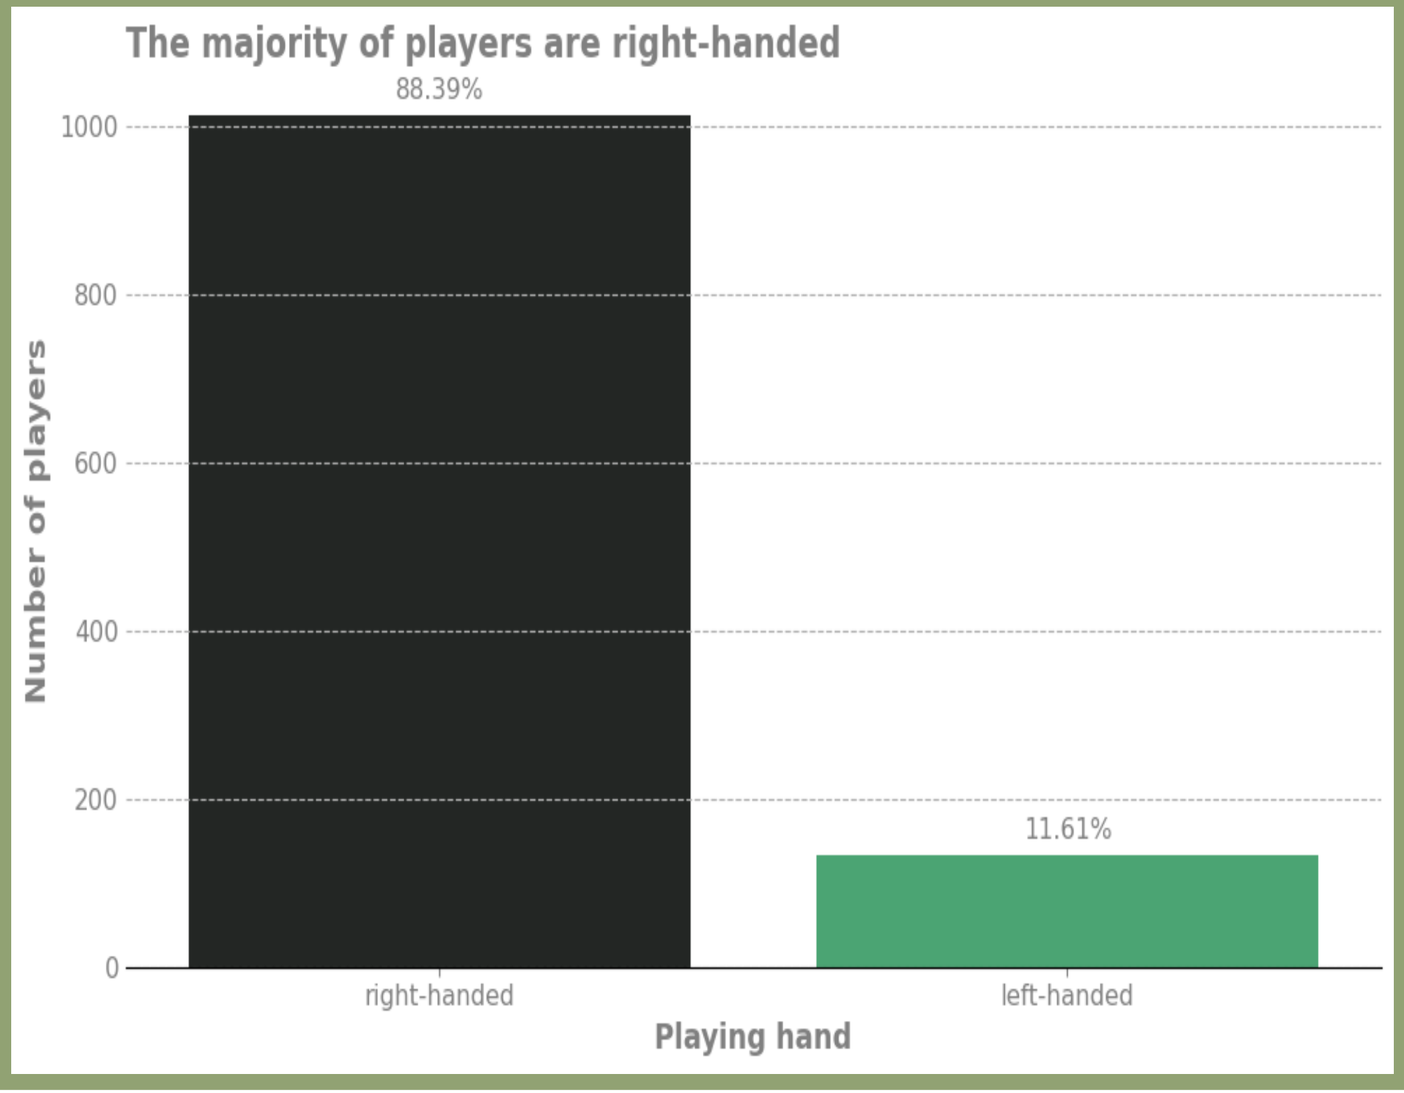


سوال ۱۱ : میانگین مدت زمان مسابقات چقدر است؟

۹۶,۱ دقیقه

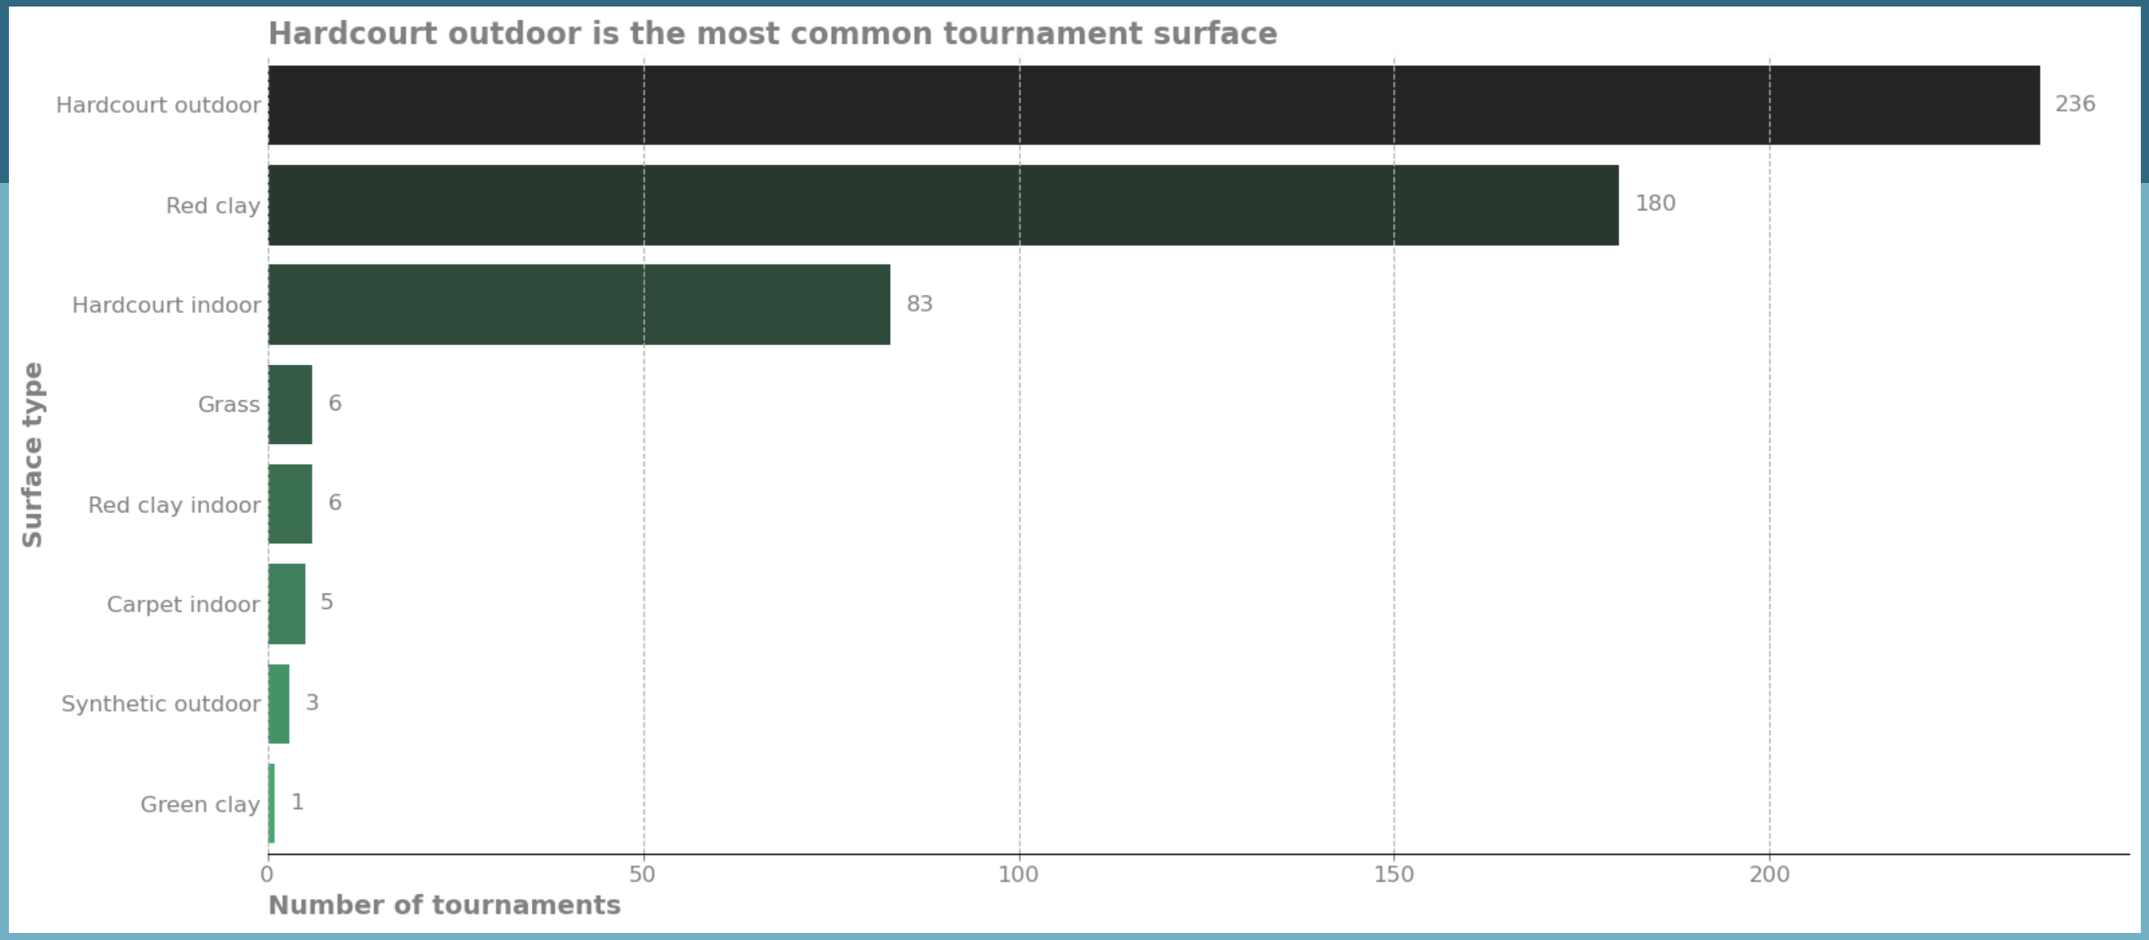
سوال ۱۲: میانگین تعداد گیم در هر ست در مسابقات مردان در مقایسه با زنان چقدر است؟





سوال ۱۳ : توزیع بازیکنان چپ‌دست در مقابل راست‌دست چگونه است؟

سوال ۱۴: رایج‌ترین نوع زمین مورد استفاده در تورنمنت‌ها چیست؟



سوال ۱۵ : چند کشور مختلف در دیتاست حضور دارند؟

۱۰۱ کشور

سوال ۱۶ : **کدام بازیکن بیشترین درصد برد را مقابل حریفان top 10 را دارد؟**

name	matches	wins	Win_pct
Humbert, Ugo	3	3	100
Swiatek, Iga	3	3	100

سوال ۱۷: میانگین تعداد بریک سرویس در هر مسابقه چقدر است؟

۶,۹۳ تعداد بریک سرویس در هر مسابقه

آیا برد در ست اول، برد مسابقه را پیش‌بینی می‌کند؟

در ۸۴.۸٪ از مسابقات، برنده ست اول در نهایت برنده کل مسابقه هم بوده است. (نشانه‌ای قوی از اهمیت شروع خوب)

آیا بازیکنان سیدشده (seeded) واقعاً عملکرد بهتری دارند؟

بله، بازیکنان سیدشده با نرخ برد ۵۵.۴٪ در مقابل ۴۸.۰٪ برای بازیکنان بدون سید، عملکرد بهتری ثبت کرده‌اند.

چند مسابقه شامل نقض قوانین استاندارد امتیازدهی تنیس هستند؟

از ۱۰،۹۵۶ مسابقه تحلیل‌شده، ۱۳۴ مسابقه (۱,۲۲٪) شامل نقض قوانین استاندارد امتیازدهی تنیس بودند.

آیا بازیکنی که ایس بیشتری میزند، احتمال برد بالاتری در مسابقه دارد؟

از ۷،۹۸۱ مسابقه تحلیل‌شده، بازیکن با اِیس بیشتر در ۴،۷۴۳ مورد (۵۹,۴۳٪) برنده شد و با p-value = 2.88e-64 نتیجه می‌گیریم که رابطه معناداری بین اِیس بیشتر و برد در مسابقه وجود دارد.

چند درصد از مسابقات توسط بازیکنی برده شد که ست اول را برده بود؟

۸۶,۴٪ از مسابقات توسط کسانی برنده شدند که ست اول را برده بودند.

آیا بین رنکینگ بازیکن و احتمال برد او در مسابقه رابطه ای وجود دارد؟

در ۳۲۷ مسابقه تحلیل‌شده، بازیکن با رنکینگ بهتر در ۶۲,۷٪ موارد برنده شده و بازیکن با رنکینگ بدتر در ۳۷,۳٪ موارد پیروز شده، در حالی که میانگین اختلاف رنکینگ بین دو بازیکن ۲۴۴,۶ رتبه بوده است.



با تشکر از توجه شما